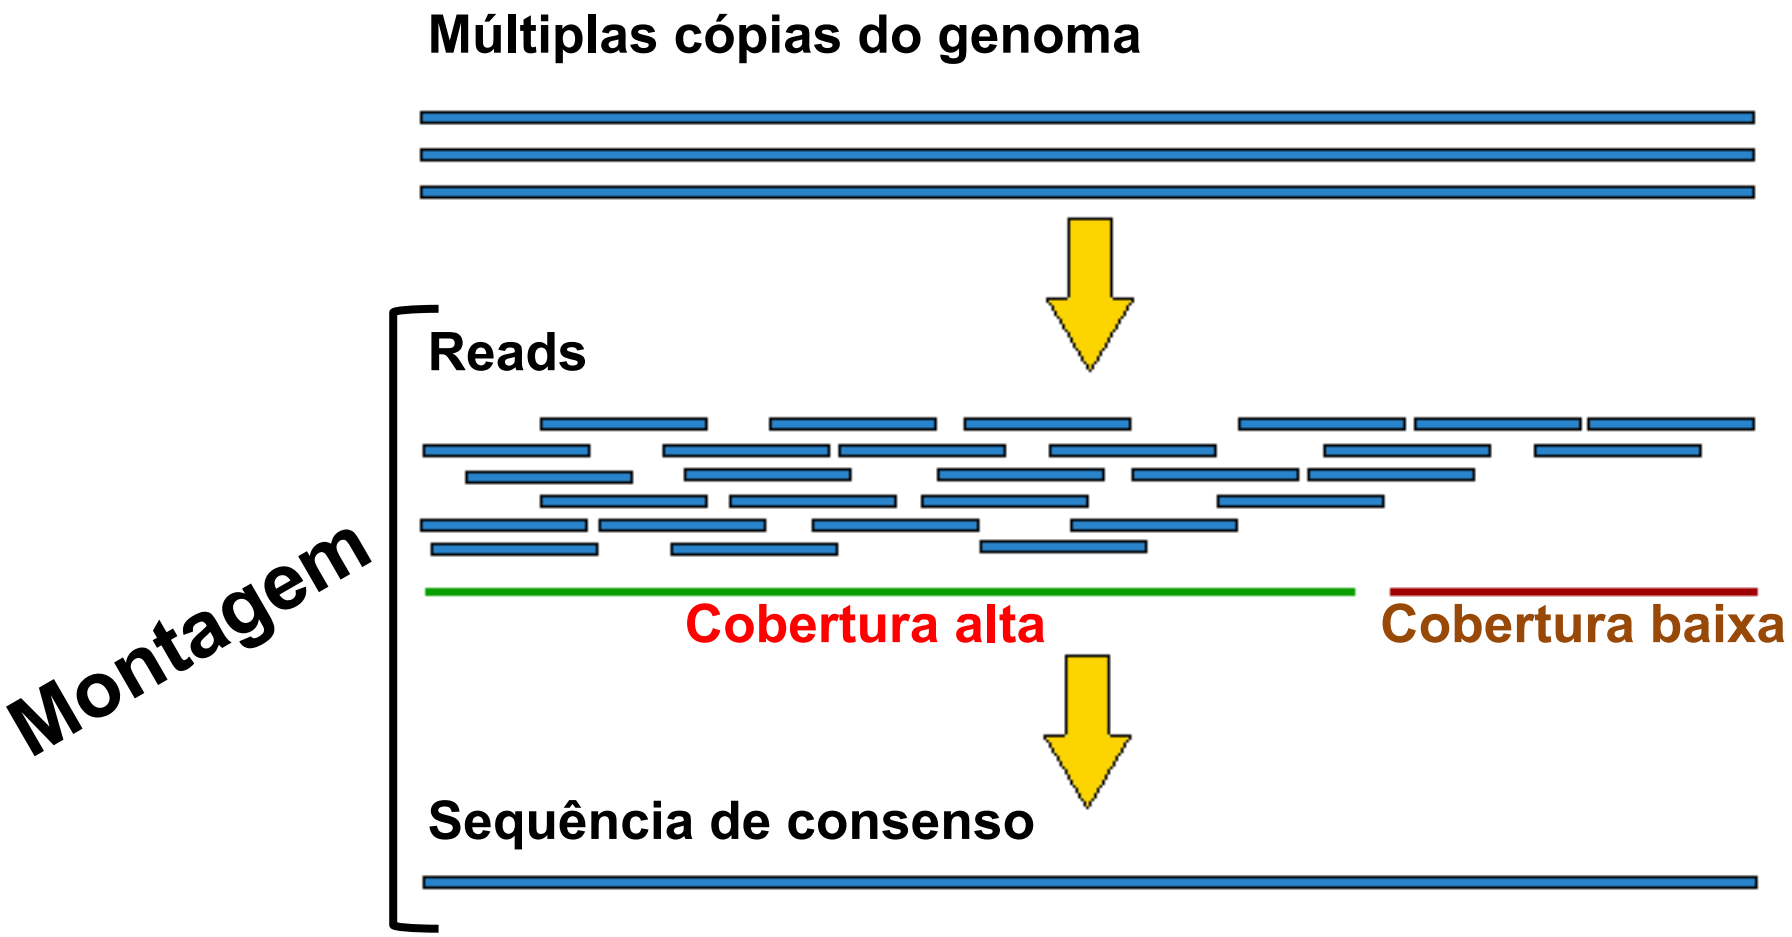
Montagem das sequências

1. Generalidades
2. Conceitos básicos
3. Avaliação
4. Desafios
5. Como montar ?



Montagem das sequências: Generalidades



Montagem das sequências: Generalidades

Cada tipo de dados e de plataforma deve ser montado com um programa específico

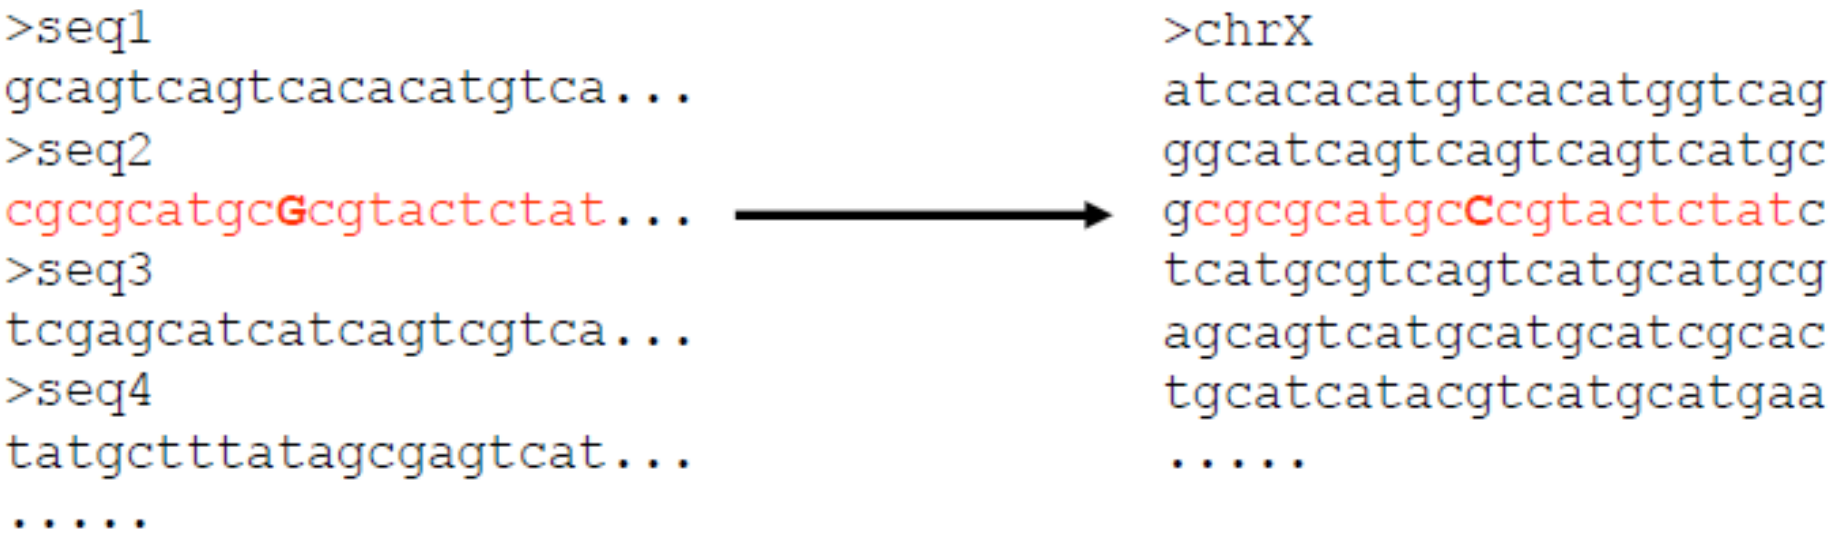


Dois tipos de montagem:

- Mapeamento contra um genoma de referência
- Montagem ‘de novo’

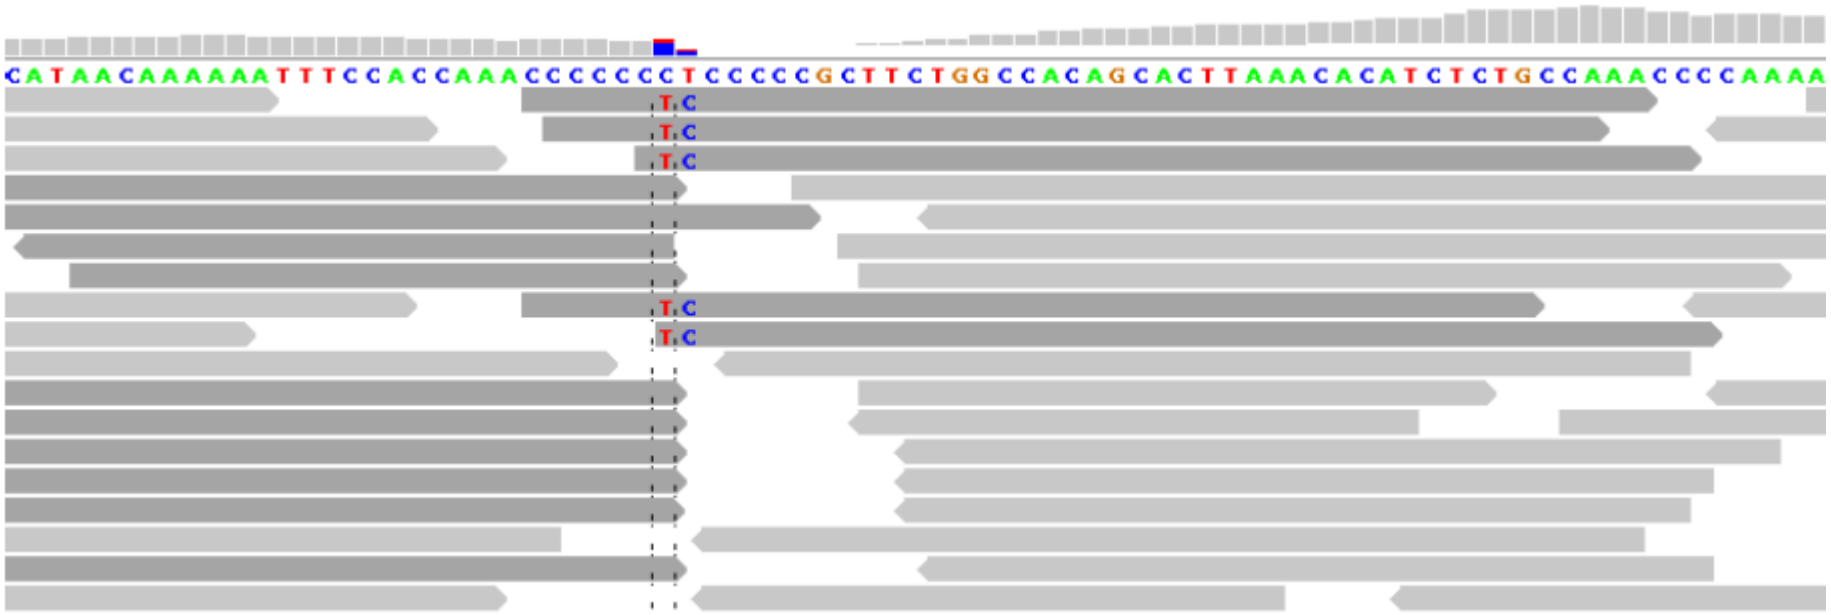
Montagem das sequências: Generalidades

Montagem baseada num genoma de refêrencia



Montagem das sequências: Generalidades

Montagem baseada num genoma de refêrencia



Programas: BWA, Bowtie, ...

Maior problema: funciona bem se for um genoma da mesma espécie ou espécie próxima

Montagem das sequências: Generalidades

Montagem *de novo*

Montagem '*de novo*' = alinhamento múltiplo de reads



Programas: Spades, Velvet, Oases, Trinity, ABySS…

Número de gaps depende da qualidade e comprimento dos reads

Exige grande capacidade computacional

Montagem das sequências: conceitos básicos

Algumas definições…

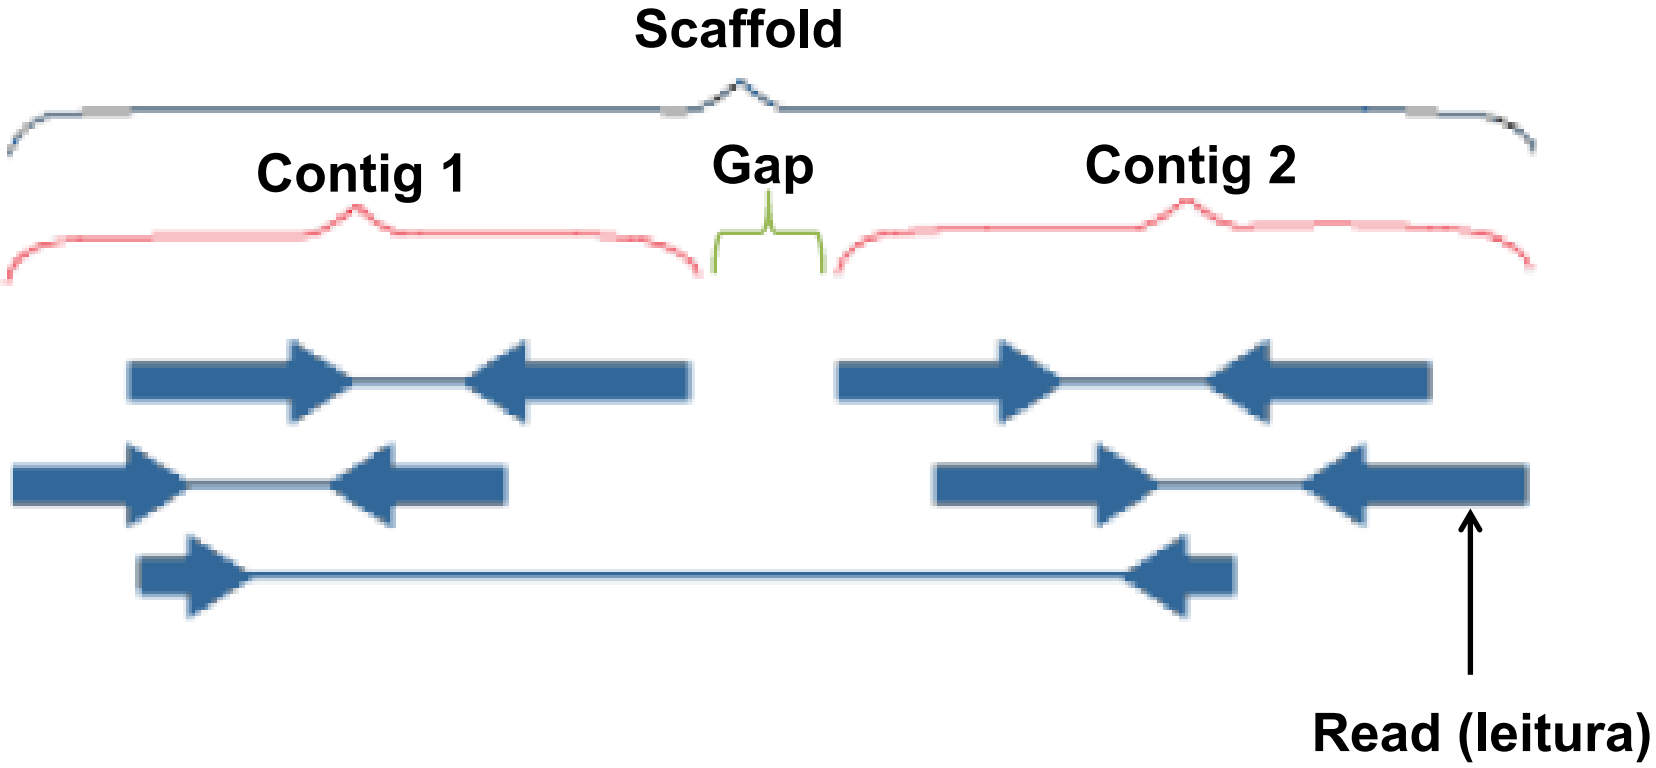
- **Contig**: alinhamento múltiplo de leituras de onde uma sequência consenso é extraída

- **Scaffold**: definem a ordem e orientação dos contigs além do tamanho dos gaps entre os contigs

- **Singlets**: leituras não agrupadas em um contig

- **Gap**: espaço entre dois contigs, onde não se conhece a sequência

Montagem das sequências: conceitos básicos



Montagem das sequências: conceitos básicos

Profundidade de sequenciamento – cobertura (*coverage*)

Total de bases sequenciadas dividido pelo tamanho da região de interesse (e.g. genoma)

$$\mathbf{(N * L)/G}$$

N: número de reads

L: tamanho do read

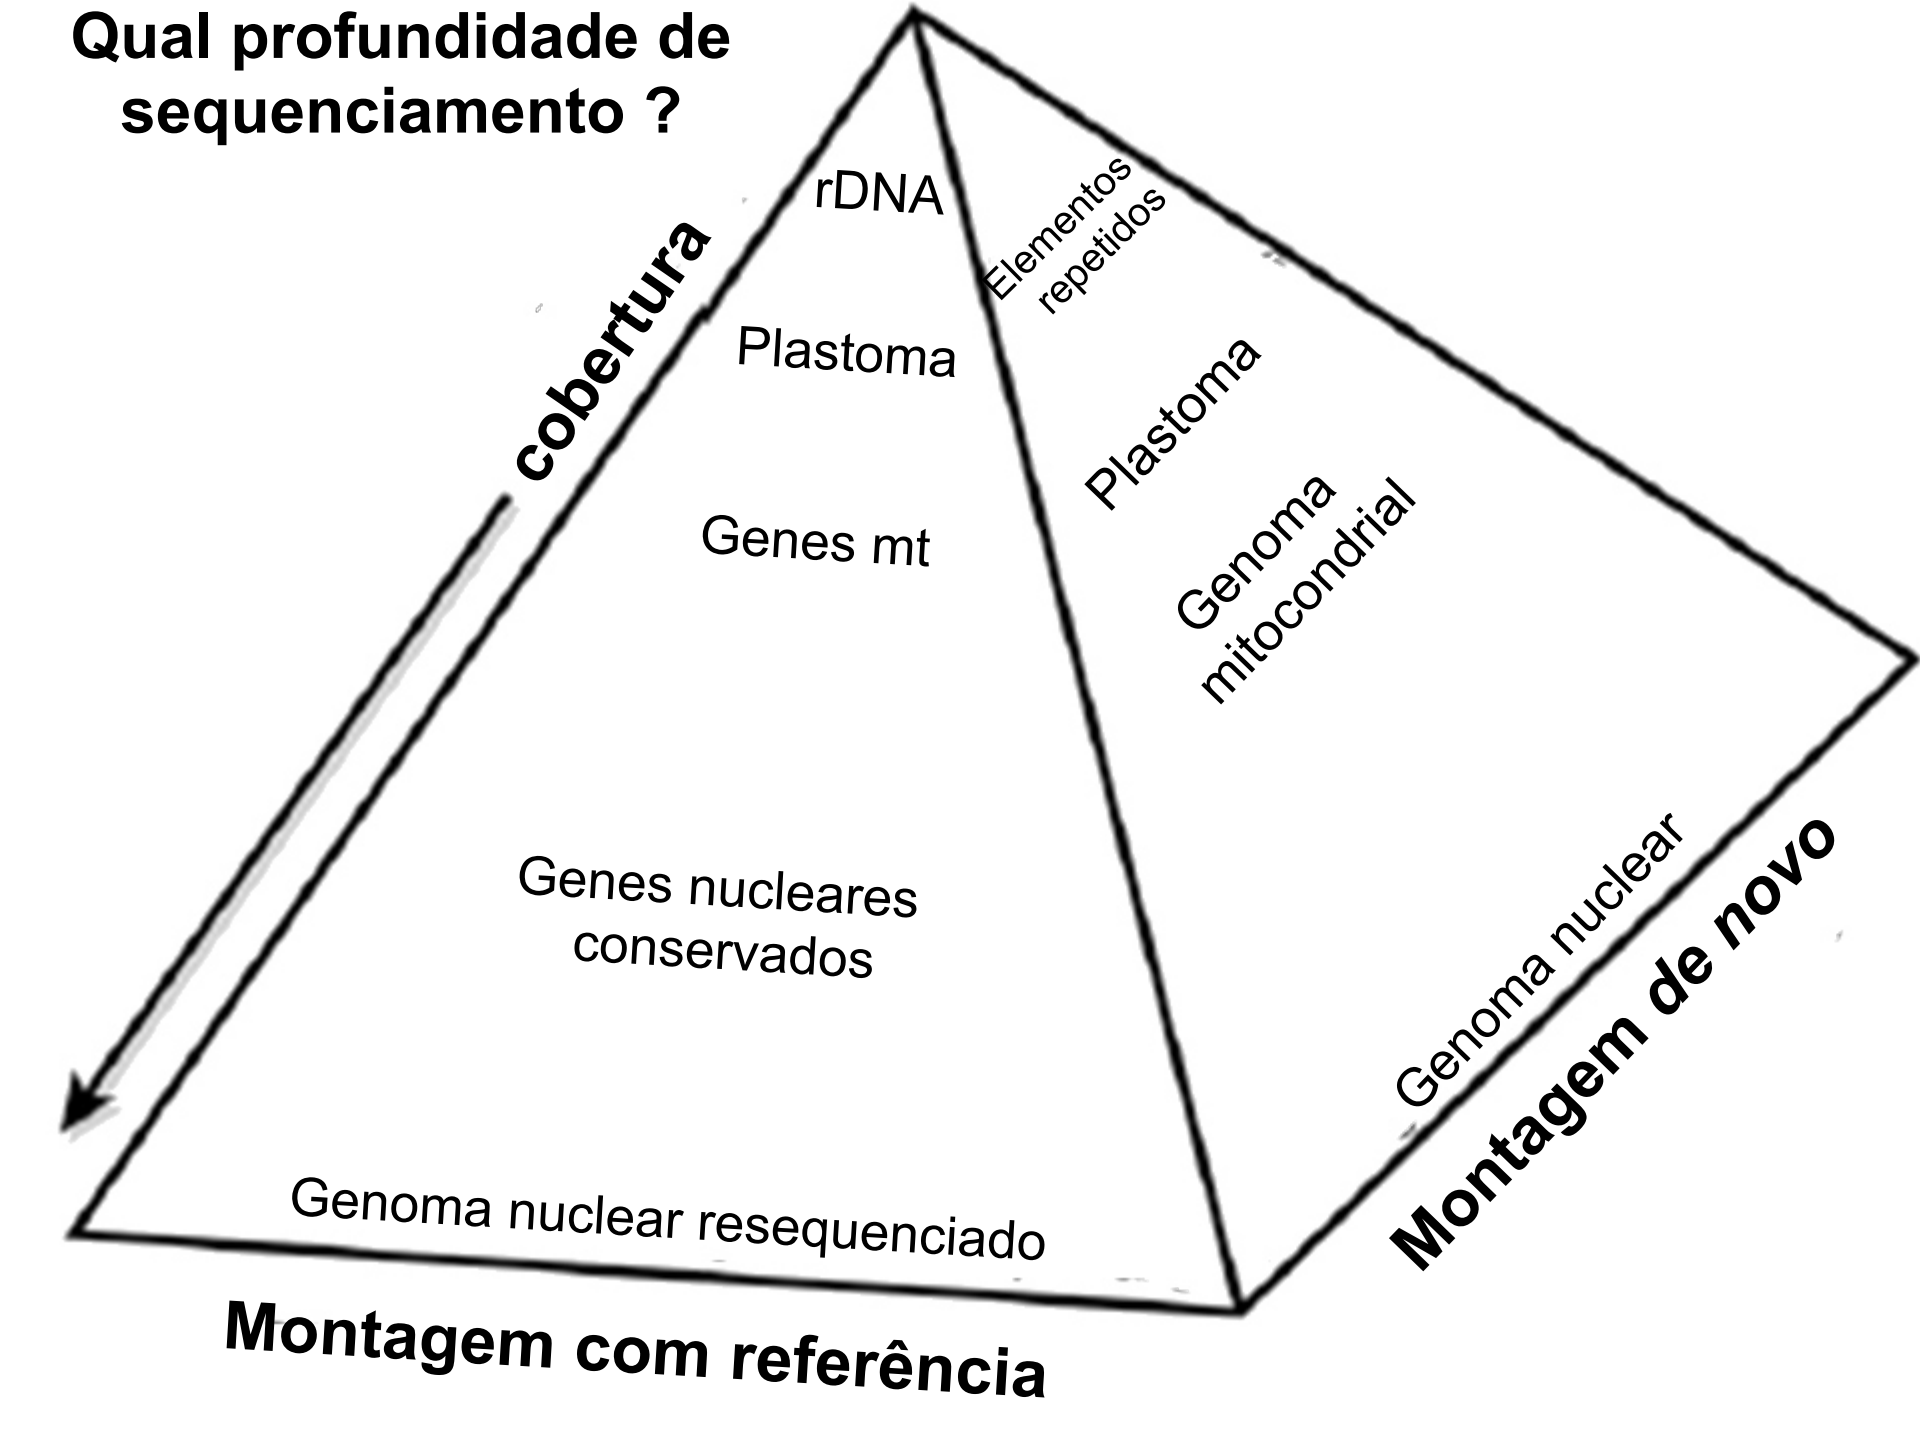
G: tamanho da região de interesse

Exemplo: Genoma de 1 M bp (G)

5 milhões de reads (N) de 50 pb (L)

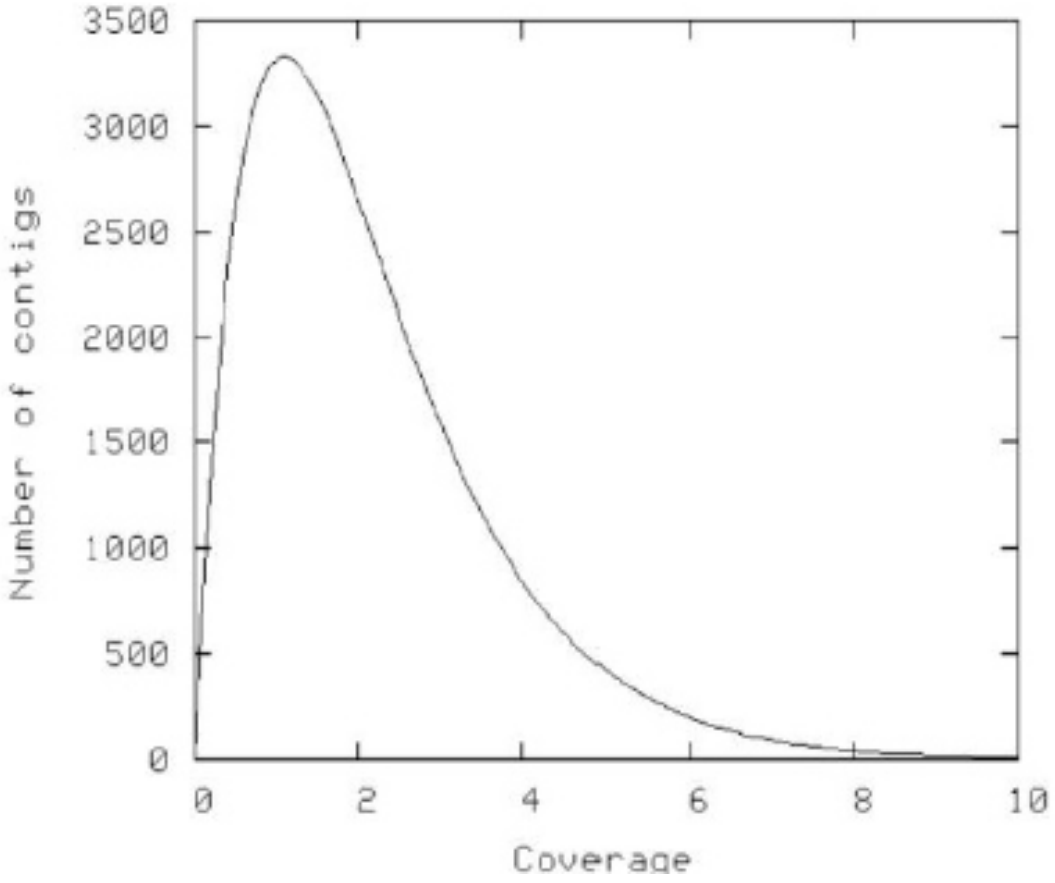
cobertura = (5.000.000 * 50)/1.000.000 = 25X

Na prática: corresponde a quantas vezes, em média, cada base do genoma foi sequenciada


Qual profundidade de sequenciamento ?
cobertura
rDNA
Plastoma
Genes mt
Genes nucleares conservados
Genoma nuclear resequenciado
Montagem com referência
Elementos repetidos
Plastoma
Genoma mitocondrial
Genoma nuclear
Montagem de novo

Montagem das sequências: conceitos básicos

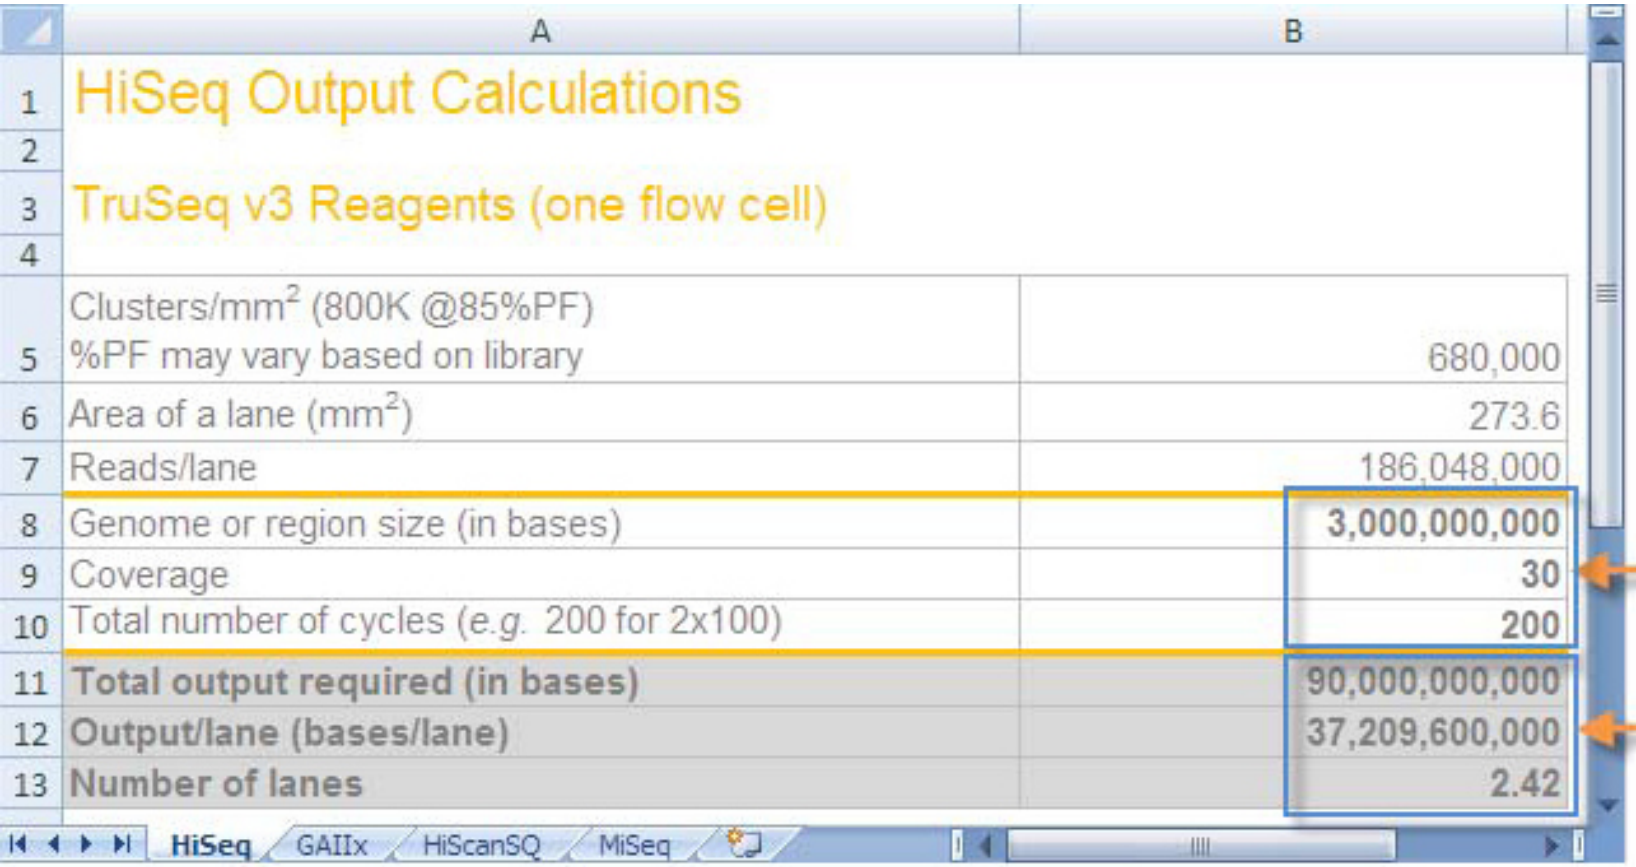
Relação contigs - cobertura



Quanto maior a cobertura menos *contigs* são produzidos, porém esses são mais longos

Montagem das sequências: conceitos básicos

Profundidade de sequenciamento – cobertura (*coverage*)



	A	B
1	HiSeq Output Calculations	
2		
3	TruSeq v3 Reagents (one flow cell)	
4		
5	Clusters/mm^2 (800K @85%PF) %PF may vary based on library	680,000
6	Area of a lane (mm^2)	273.6
7	Reads/lane	186,048,000
8	Genome or region size (in bases)	3,000,000,000
9	Coverage	30
10	Total number of cycles (*e.g.* 200 for 2x100)	200
11	**Total output required (in bases)**	90,000,000,000
12	**Output/lane (bases/lane)**	37,209,600,000
13	**Number of lanes**	2.42

HiSeq | GAIIx | HiScanSQ | MiSeq

Entrar os valores desejados

Resultados em n° de canaletas

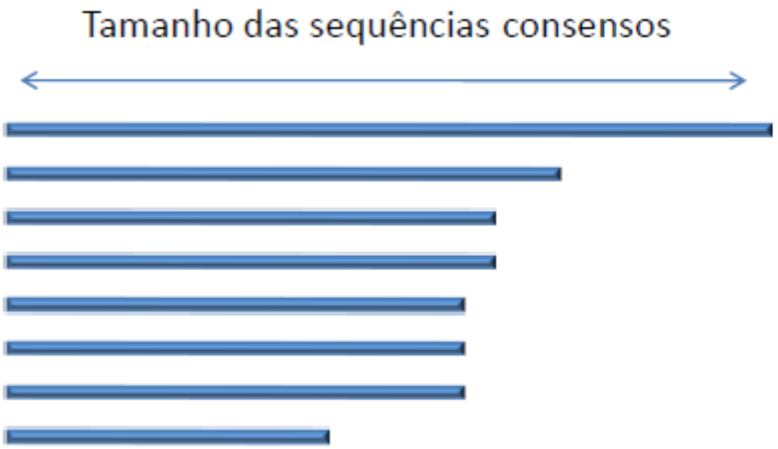
Selecionar o sequenciador

http://www.illumina.com/CoverageCalculator

Montagem das sequências: avaliação

Montagens bem sucedidas

Montagens são medidas pelo (1) tamanho e (2) precisão dos *contigs* e *scaffolds*



(1)Tamanhos das sequências obtidas

- Tamanho máximo
- Tamanho médio
- Tamanho total combinado

N50 = tamanho do menor contig no conjunto dos maiores contigs que combinados representam 50% da montagem

- valores muito altos: erros na montagem
- valores muito baixos: montagem incompleta

Montagem das sequências: avaliação

Montagens bem sucedidas

Montagens são medidas pelo (1) tamanho
e (2) precisão dos *contigs* e *scaffolds*

(2) *Precisão dos contigs e scaffolds*

- Sequências sobrepostas no *contig* devem ter - concordância entre si
- Sequências em paired-ends devem ser consistentes com tamanho do fragmento e orientação

Montagem das sequências: desafios

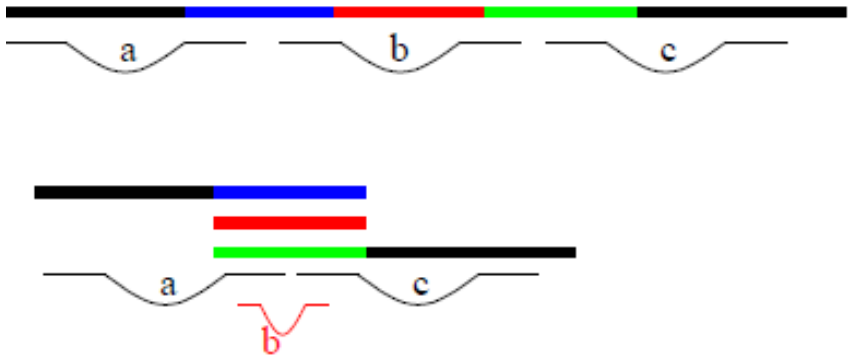
Os diferentes desafios

- Contaminantes nas amostras (e.g. bactéria)
- RNA ribosomal
- Artefatos gerados durante a PCR (e.g. mutações)
- Poliploidia e heterozigose
- Erros de sequenciamento
- Viéses de composição (conteúdo de GC)
- Repetições

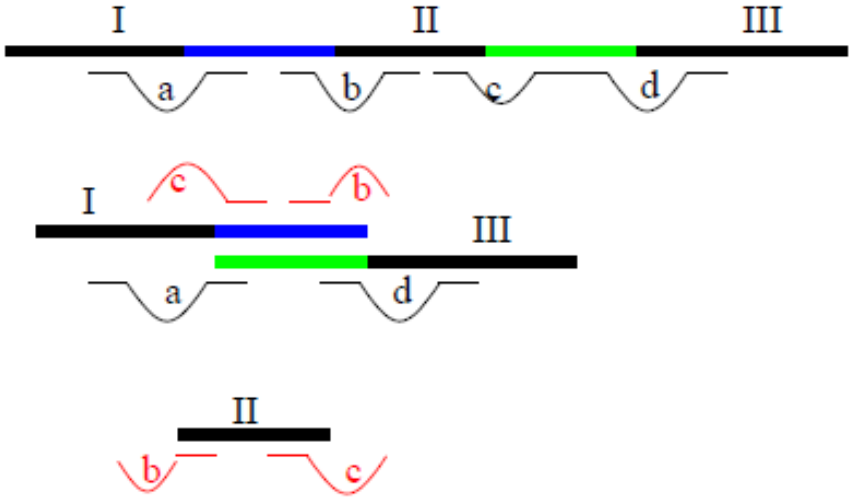
Montagem das sequências: desafios

Problema das repetições

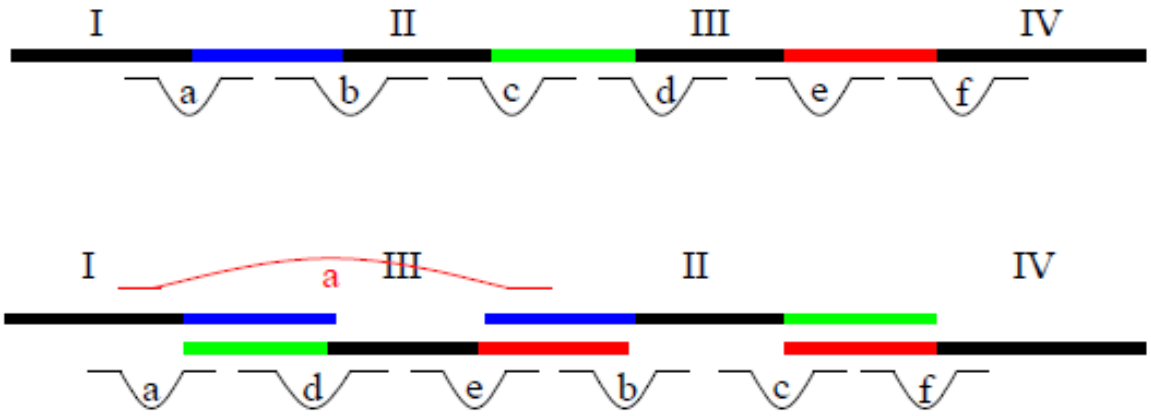
Tandem colapsado



Excisão



Rearranjo

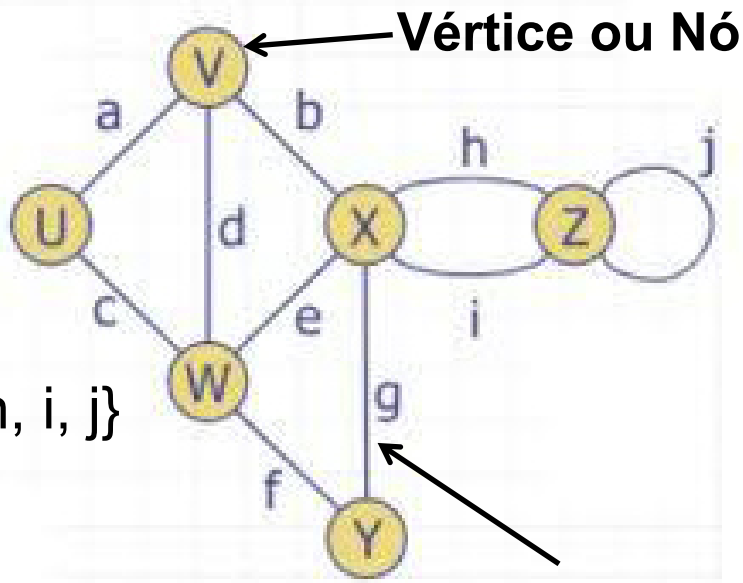


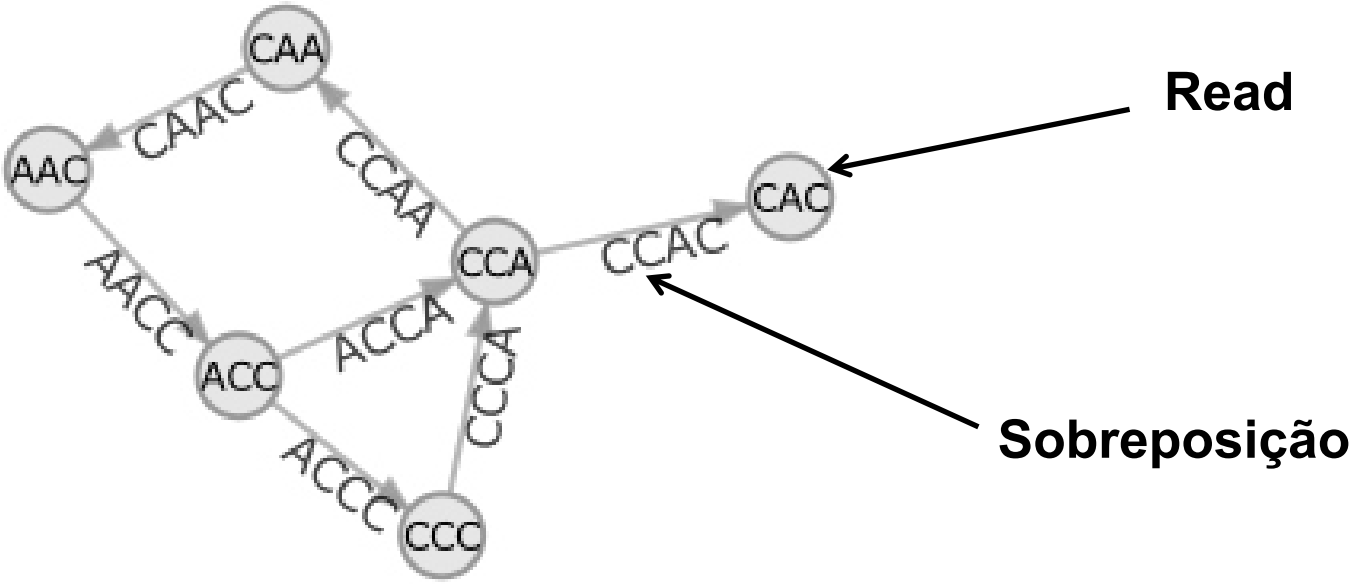
Montagem das sequências: como montar ?

Teoria dos grafos

Grafo = estrutura G(V,A)

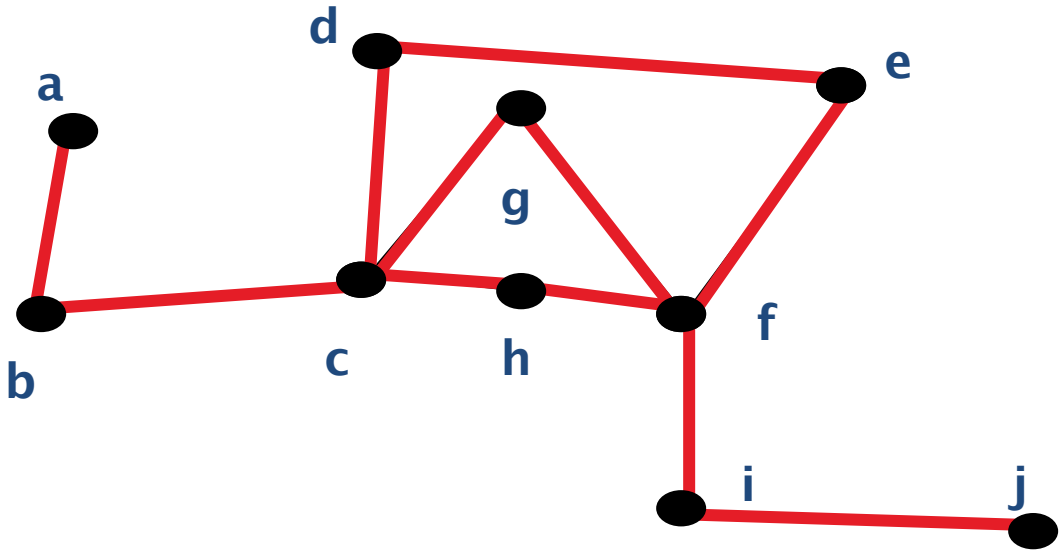
Nós (vértices): V = {U, V, W, X, Y, Z}
Arestas (arcos): A = {a, b, c, d, e, f, g, h, i, j}





Montagem das sequências: como montar ?

Teoria dos grafos e algoritmos de montagem

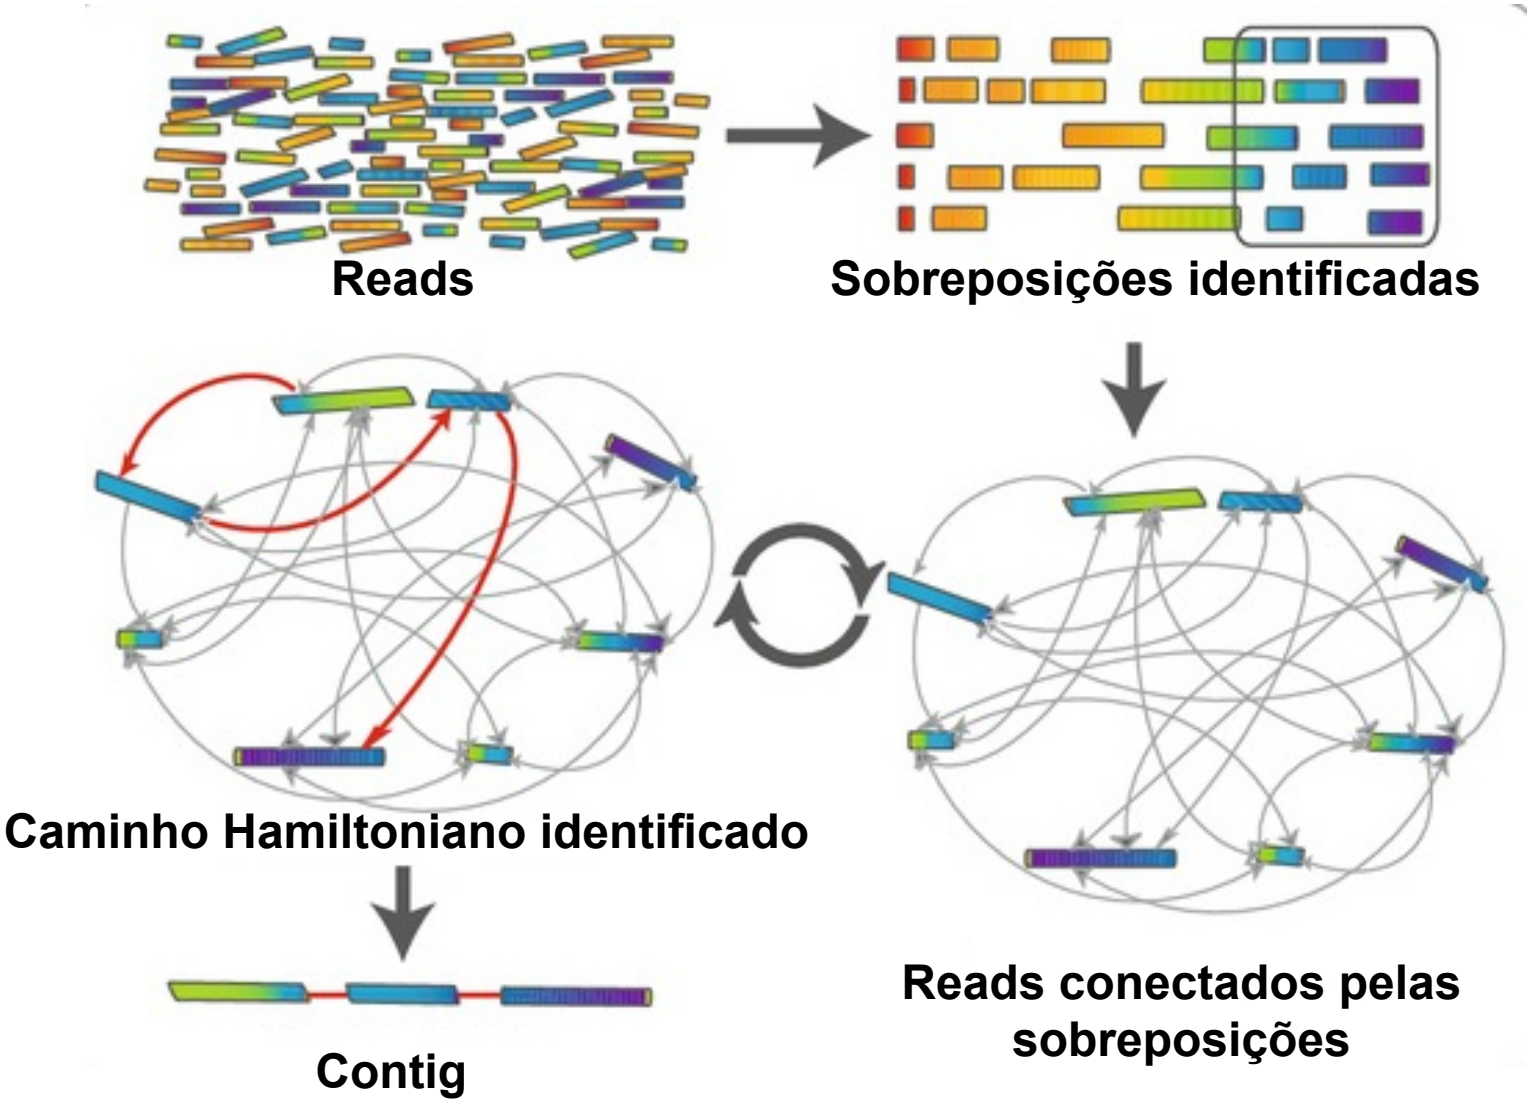


Caminho Hamiltoniano

Caminho que permite passar uma única vez por todos os nós do grafo = **contig**

Montagem das sequências: como montar ?

Overlap/Layout/Consensus (OLC)



Montagem das sequências: como montar ?

Grafos de De Bruijn

K-mers

Subsequência de tamanho **k**

Em uma sequência de tamanho **L** há (**L-k+1**) k-mers

Exemplo: sequência de tamanho L=8 tem 5 k-mers com k=4

Nicolaas Govert de Bruijn



ACGTACGA

ACGT

CGTA

GTAC

TACG

ACGA

Montagem das sequências: como montar ?

Grafos de De Bruijn

Grafos k-mers

Nós: todas as subsequências de tamanho **k**

Arestas: todas as sobreposições (k-1 bases) entre essas subsqüências que são consecutivas na sequência original

AACCGG

k-mer = 4

AACC
 ACCG
  CCGG

CCGGTT

k-mer = 4

CCGG
 CGGT
  GGTT

Exemplo: k= 4 => arestas represetarão as sobreposição de k-1 (3) bases

Montagem das sequências: como montar ?

Grafos de De Bruijn

Tamanho de k: Não pode ser nem muito grande, nem muito pequeno

- grande o suficiente para não pegar falsas sobreposições (resoluções de repetições)

- pequeno o suficiente para encontrar o máximo de sobreposições verdadeiras

Solução para minimizar o problema: combinar as informações dos grafos com diferentes valores de k-mers

Montagem das sequências: como montar ?

Grafos de De Bruijn

Programas usando grafos de De Bruijn para montagem:

- **Velvet/Oases** (http://www.ebi.ac.uk/~zerbino/velvet/)
  - Illumina, SOLiD
  - Genoma (Velvet), cDNA (Oases)
- **ABySS/Trans-ABySS** (http://www.bcgsc.ca/platform/bioinfo/software/abyss)
  - Illumina, SOLiD
  - cDNA
- **Trinity** (http://trinityrnaseq.sourceforge.net/)
  - Illumina, 454, SOLiD
  - cDNA, Transcriptomas
- **SPAdes** (http://cab.spbu.ru/software/spades/)
  - Genomas pequenos, target capture





Montagem das sequências: como montar?

Mais atualmente:

-modelos mistos entre montagem de novo e com referência



Fast-Plast: montagem de genomas de cloroplasto de novo, usando referência para fechar gaps

Phyluce, HybPiper: utilizam montagem de novo e mapeamento contra referência (sequências de sondas) para recuperar alvos de target capture